로봇 알고리즘 프로젝트_1주차

소프트웨어학부 2024245046 김지민

1. Git Repository 생성

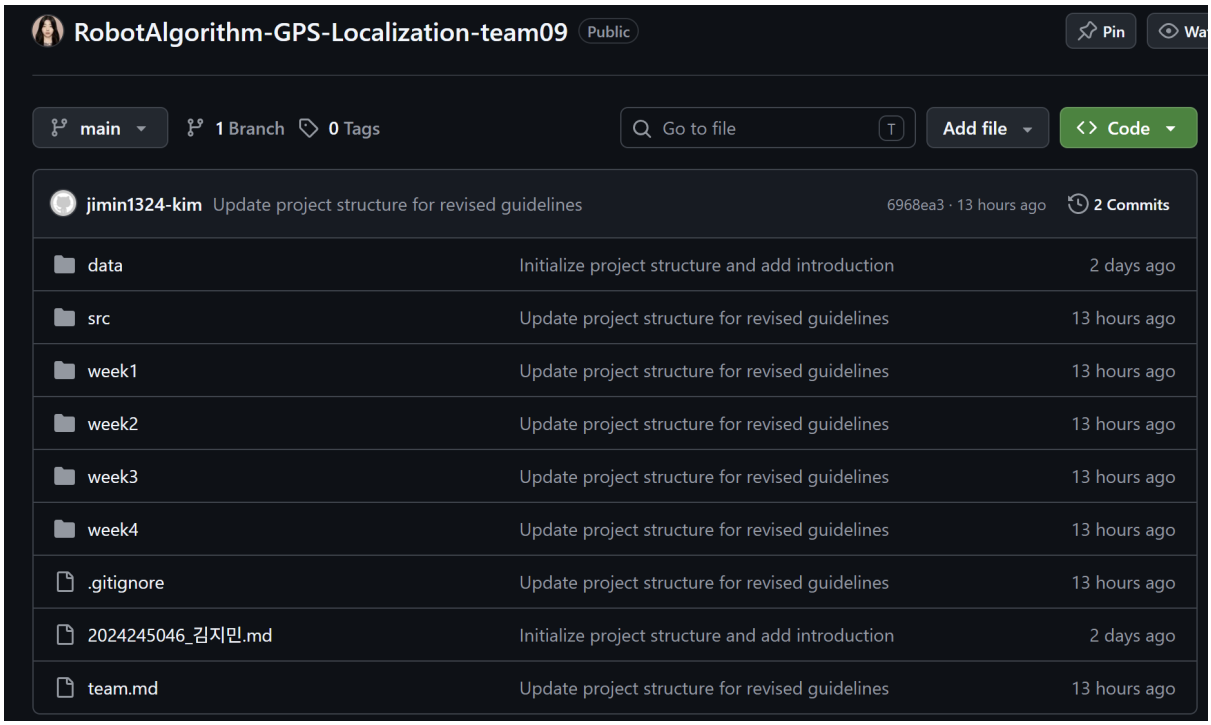
1.1 프로젝트 저장소 생성

개인 프로젝트로 진행하며, Git Repository 이름은 RobotAlgorithm-GPS-Localization-team09로 설정했다.

Ubuntu 22.04 환경에서 다음 명령어를 실행하여 원격 저장소를 복제했다.

[git clone https://github.com/jimin1324-kim/RobotAlgorithm-GPS-Localization-team09.git]

개인 프로젝트로 진행하기 때문에 팀원 초대 과정은 생략했다.



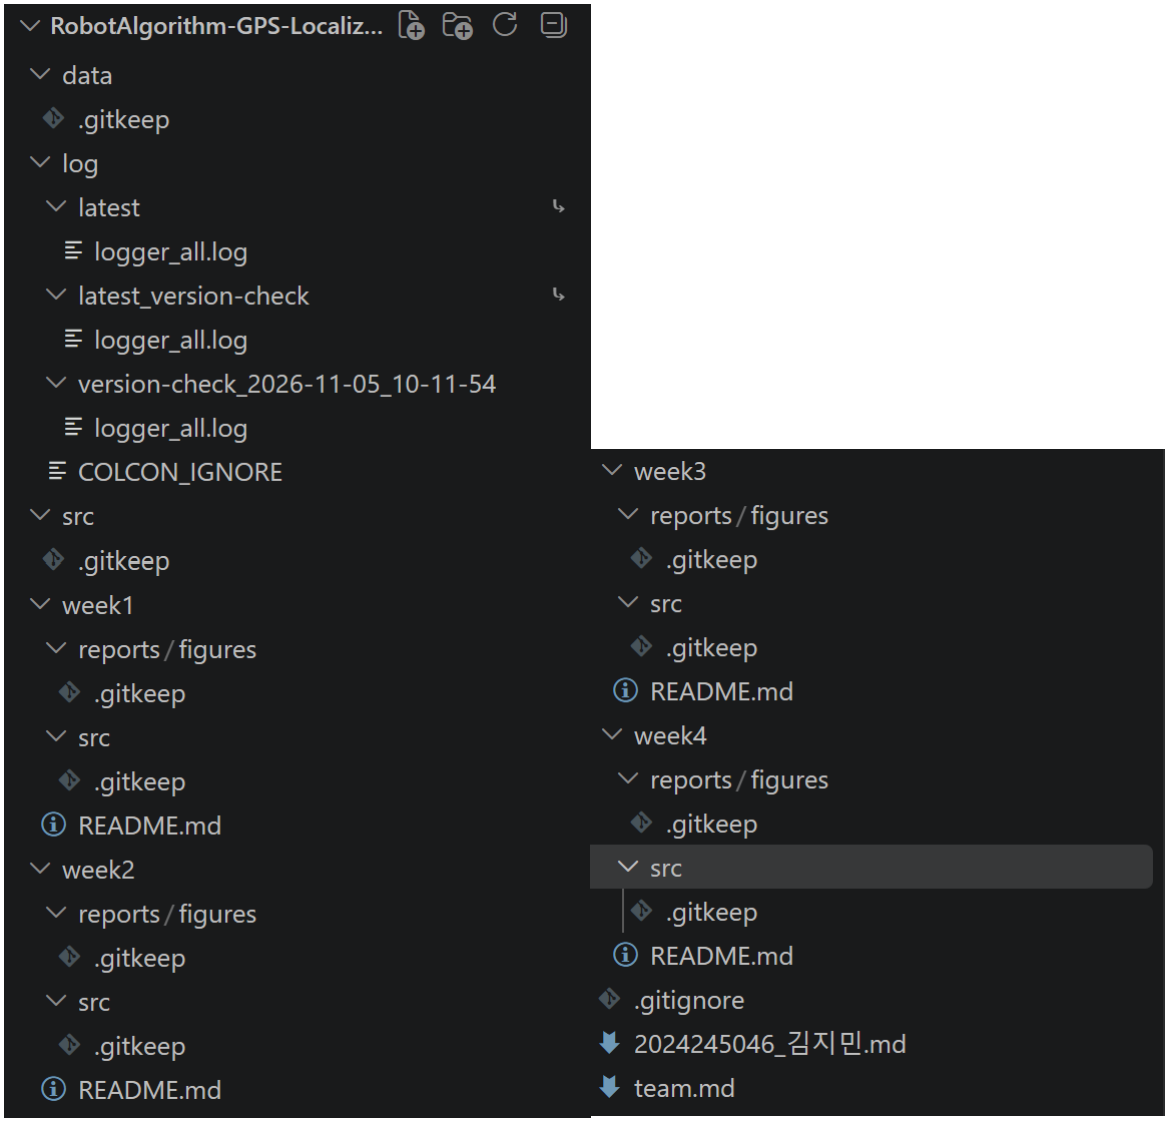
1.2 프로젝트 폴더 구조 생성

과제 안내문에 맞춰 폴더 구조를 구성했다.

최상위 디렉터리에 team.md, .gitignore, src/ 및 week1/부터 week4/까지의 폴더를 생성했다.

각 주차별 디렉터리에는 README.md, src/, reports/figures/를 생성했다.

또한 Git은 빈 디렉터리를 직접 추적하지 않기 때문에 .gitkeep 파일을 생성했다.

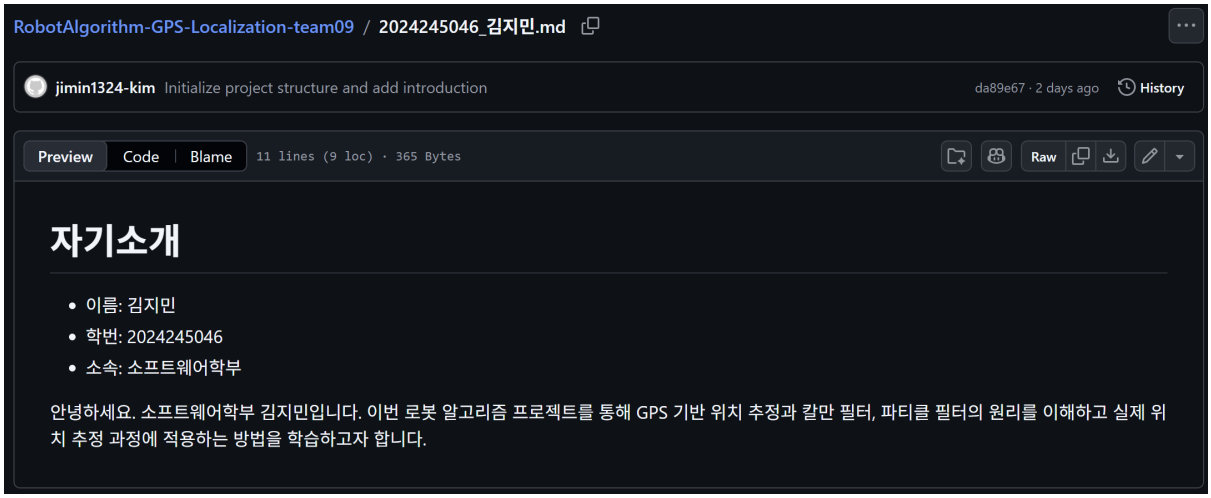


1.3 자기소개 파일 작성 및 push

2024245046_김지민.md 파일을 생성하고, 자기소개 파일과 폴더 구조를 GitHub에 업로드했다.

- git add .: 변경된 파일을 Staging Area에 등록
- git commit -m "Update project structure for revised guidelines": 변경 사항을 로컬 저장소의 커밋으로 기록
- git push -u origin main: 로컬 커밋을 원격 GitHub Repository에 업로드

이후 수정된 프로젝트 안내문을 반영하기 위해 추가 commit, push를 진행했다.

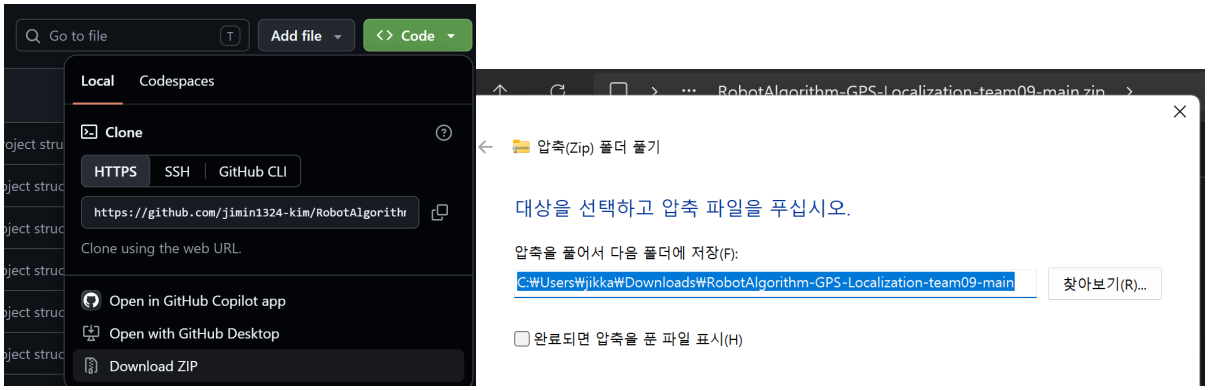


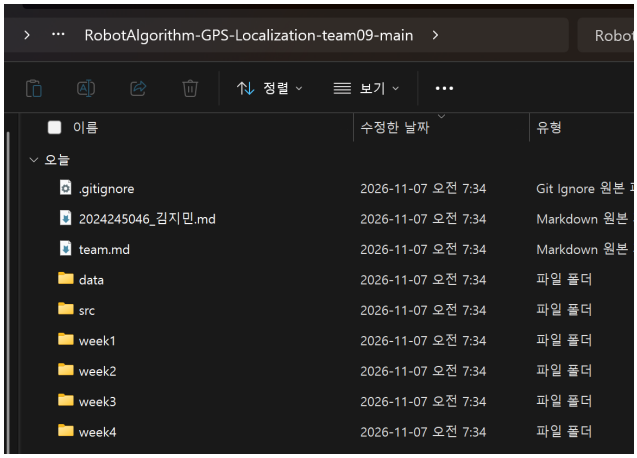
1.4 GitHub 홈페이지에서 확인 및 다운로드

GitHub Repository에 업로드된 프로젝트 파일이 정상적으로 저장되었는지 확인하기 위해 GitHub 웹페이지에서 업로드 결과를 확인했다.

이후 Repository의 Code → Download ZIP을 눌러 프로젝트 전체를 ZIP 형태로 다운로드 했다.

주차별 디렉터리에 파일과 폴더가 생성되어 있는지 확인하고, GitHub에 업로드한 내용과 일치하는지 확인했다.





2. 프로젝트 진행을 위한 전공 배경지식

2.1 경로 계획 문제에서 샘플링이 필요한 이유, 관련 알고리즘

경로 계획(Path Planning)은 로봇이 출발점에서 목표점까지 장애물과 충돌하지 않고 이동할 수 있는 경로를 찾는 문제이다.
Configuration Space는 연속적인 상태 공간이며, 로봇의 자유도가 증가할수록 탐색 공간의 차원이 높아진다.
Sampling-Based Path Planning은 전체 Configuration Space를 직접 구성하는 대신, 일부를 선택하고 충돌 검사와 부분 경로 연결을 통해 이동 가능한 경로를 탐색하는 방법이다. 이를 통해 고차원 구성 공간의 기하학적 구조를 명시적으로 계산해야 하는 부담을 줄이고 복잡한 장애물 환경에서도 경로를 탐색할 수 있다.

[Sampling-Based Method Algorithm]
1. PRM(Probabilistic Roadmap Method): 충돌하지 않는 Configuration State를 Sampling하고 연결하여 Roadmap을 구성하는 알고리즘이다.

2. EST(Expansive-Spaces Tree): 탐색 트리에서 확장할 상태를 선택하고 주변 자유 공간을 Sampling하여 트리를 확장하는 방법이다.

3. RRT(Rapidly-exploring Random Tree): Random으로 선택한 Configuration State를 향해 기존 트리를 확장하며 Free Space를 탐색하는 알고리즘이다.

4. SRT(Sampling-based Roadmap of Tree): PRM, EST, RRT의 특징을 결합한 알고리즘이다.

하지만 Sampling-Based Method는 좁은 통로와 같은 환경에서 유효한 표본을 찾기 어려울 수 있으며, 유한한 표본 수만으로 경로 발견이나 최적해를 보장하지 않는다.

2.2 Kalman Filter

Kalman Filter: 잡음과 불확실성이 존재하는 동적 시스템에서 시스템의 상태를 추정하기 위한 재귀적 상태 추정 알고리즘이다. 이전 시점의 상태 추정값과 시스템 운동 모델을 이용한 예측, 새로운 센서 측정값을 반영하는 보정 과정을 반복하여 현재 상태를 추정한다.
Kalman Filter는 시스템 상태를 평균과 공분산으로 표현하며, 선형 시스템과 Gaussian Noise 가정 하에 확률적인 상태 추정을 수행한다.
예측 단계: 이전 상태 추정값과 제어 입력을 이용해 현재 상태를 예측하고, Process Noise 공분산을 반영하여 예측 불확실성을 계산한다.
보정 단계: 새롭게 관측된 센서 측정값과 예측값의 차이를 구하고, Kalman Gain을 이용하여 상태 추정값을 갱신한다. Kalman Gain은 예측 상태의 불확실성과 센서 측정의 불확실

성을 고려하여 보정 정도를 결정한다.

Kalman Filter은 센서 측정값에 Noise가 존재하거나 시스템의 움직임에 불확실성이 있어 실제 상태를 정확하게 알기 어려운 경우에 필요하다.
ex) GPS를 이용한 이동 로봇의 위치 추정에서는 센서 측정값과 로봇의 이동 모델에 각각 오차가 발생할 수 있다. 이때 Kalman Filter를 사용할 경우 두 정보를 불확실성에 따라 결합하여 로봇의 현재 위치를 지속적으로 추정할 수 있도록 한다.

따라서 Kalman Filter는 위치 및 속도 추정과 같이 시간이 지남에 따라 변화하는 상태를 추정하는 데 활용할 수 있다.

2.3 Particle Filter

Particle Filter는 여러 개의 Particle을 이용하여 시스템의 상태에 대한 확률분포를 근사하는 Bayesian Filter 기반의 상태 추정 알고리즘이다. 각 Particle은 시스템이 가질 수 있는 하나의 상태를 나타내며, Particle마다 해당 상태의 가능성을 나타내는 Weight가 부여된다.

Particle Filter는 일반적으로 초기화, 예측, 가중치 계산, 재표본추출의 과정을 반복한다.
- 초기화 단계: 가능한 상태를 나타내는 여러 Particle을 생성
- 예측 단계: 시스템의 운동 모델과 제어 입력을 이용하여 각 Particle의 상태를 갱신
- 가중치 계산 단계: 센서 측정값과 각 Particle의 관측값이 얼마나 일치하는지를 평가하여 가중치 부여
- 재표본추출 단계: 가중치가 높은 Particle이 선택될 확률을 높여 새로운 Particle 집합 구성

Particle Filter는 시스템의 상태 변화가 비선형적이거나 상태에 대한 확률분포가 Gaussian Distribution으로 표현되기 어려운 경우에 유용하다. 또한 여러 위치 후보가 동시에 존재하는 상황에서도 각 후보의 가능성을 유지하며 상태를 추정할 수 있다.
ex) GPS 측정값에 오차가 있거나 로봇의 초기 위치가 불확실한 경우, 여러 개의 Particle을 통해 가능한 위치를 표현하고 이동정보와 센서 측정값을 반복적으로 반영하여 로봇의 위치 추정이 가능하다.

따라서 Particle Filter는 불확실성이 크고 복잡한 환경에서 이동 로봇의 위치를 추정하는 Localization 문제 등에 활용된다.

2.4 Important Sample, Particle에서 왜 필요한가

Important Sampling: Target Distribution에서 직접 샘플을 생성하기 어렵거나 비효율적인

경우, 다른 Distribution인 Proposal Distribution에서 샘플을 생성하고 Importance Weight를 부여하여 Target Distribution을 근사하는 방법이다.

Target Distribution: p(x), Proposal Distribution: q(x) 일 때, 각 샘플에 부여되는 중요도 가중치

$$w^{(i)} \propto p(x^{(i)}) / q(x^{(i)})$$

가중치는 샘플이 생성된 분포와 실제로 추정하려는 분포의 차이를 보정하는 역할을 한다.

Particle Filter에서는 여러 Particle을 이용해 시스템 상태의 확률분포를 근사하지만, Particle마다 실제 상태를 나타낼 가능성이 다르다. 다라서 각 Particle에 중요도 가중치를 부여하여 상태 추정에 대한 기여도를 조정할 필요가 있다.
일반적인 Particle Filter에서는 운동 모델을 이용하여 입자의 상태를 예측하고, 센서 측정값과 각 입자의 상태가 얼마나 일치하는지에 따라 가중치를 계산한다. 운동 모델에서 입자를 생성하는 경우, 중요도 가중치는 해당 입자 상태에서 센서 측정값이 관측될 가능도에 비례한다.

이후 가중치를 정규화하고 재표본추출을 수행하여 가중치가 높은 Particle이 더 많이 선택되도록 한다. 이를 통해 관측값에 부합하지 않은 Particle의 영향은 감소시키고, 실제 상태일 가능성이 높은 영역에 Particle을 집중시킬 수 있다.

따라서 Importance Sampling은 Particle Filter가 제한된 수의 Particle로 Target Distribution을 근사하고, 센서 관측 정보를 반영하여 상태 추정을 수행하는 데 중요한 역할을 한다.

2.5 Localization 문제를 푸는 이유, 현실 문제와 대응

Localization: 로봇에 주변 환경과 센서 측정값, 이동 정보를 이용하여 현재 자신의 위치와 자세를 추정하는 문제이다.
로봇은 자신의 실제 위치를 항상 정확하게 알 수 없으며, 이동 명령과 센서 측정값에는 불확실성과 오차가 존재한다. 예를 들어 로봇이 특정 거리만큼 이동하도록 명령을 받아도 미끄러짐이나 제어 오차로 인해 실제 이동거리가 달라질 수 있다. 또한 GPS와 같은 위치 센서도 측정 오차를 포함할 수 있다.
이런 오차가 누적되면 로봇이 추정하는 위치와 실제 위치 사이의 차이가 커질 수 있으며, Path Planning과 자율주행의 정확성이 저하될 수 있다. 따라서 로봇은 이동 정보와 센서 관측값을 함께 이용하여 자신의 위치를 지속적으로 추정해야 한다.

Localization에서는 로봇의 상태에 대한 확률분포를 이용하여 위치의 불확실성을 표현할 수 있다. Bayesian Filter는 이전 상태와 운동 모델을 이용해 현재 상태를 예측하고, 새로

운 센서 측정값을 반영해 확률분포를 갱신한다.
ex) 여러 개의 비슷한 문이 존재하는 복도에서 로봇이 문을 관측해도 어느 위치에 있는지 바로 판단하기가 어렵다. 하지만 로봇이 이동하면서 추가적인 관측을 수행하면 위치 후보들의 확률이 달라지고, 이를 이용해 현재 위치를 추정할 수 있다.

현실에서 Localization이 활용되는 대표적인 사례는 자율주행 자동차, 실내 자율주행 로봇, 배달 로봇, 드론의 위치 추정 문제이다. 특히 GPS를 활용한 캠퍼스 자율주행 로봇에서는 GPS 측정 오차와 로봇의 이동 오차를 고려하여 실제 위치를 추정하는 과정이 필요하다.

따라서 Localization은 로봇이 불확실한 환경에서도 자신의 위치를 파악하고, 안전하고 정확하게 이동하기 위한 핵심적인 문제이다.

2.6 Occupancy grid map, 센서 측정으로 만드는 방법

Occupancy Grid Map은 로봇의 주변 환경을 일정한 크기의 격자로 분할하고, 각 셀에 장애물이 존재할 확률을 저장해 환경을 표현하는 Map Method이다.

각 셀은 Occupancy Probability를 가지며, Occupancy Probability가 0에 가까울수록 Free Space일 가능성이 높고, 1에 가까울수록 장애물이 있는 Occupied Space일 가능성이 높다. Occupancy Probability이 0.5인 경우에는 해당 셀의 점유 여부에 대한 정보가 부족한 Unknown Space로 볼 수 있다.

Occupancy Grid Map은 LiDAR, 초음파 센서 등으로 얻은 거리 측정값을 활용하여 생성할 수 있다.
1. 격자 분할(Grid Discretization): 지도 영역을 일정한 크기의 셀로 나누고, 사전 정보가 없는 경우 각 셀의 초기 Occupancy Probability를 0.5로 설정한다.
2. 센서 측정(Sensor Measurement): 로봇에 장착된 LiDAR 또는 초음파 센서를 이용하여 주변 장애물까지의 거리와 방향을 측정한다.
3. 좌표 변환(Coordinate Transformation): 로봇의 위치 및 자세를 이용해 센서 좌표계에서 얻은 측정값을 지도 좌표계로 변환한다.
4. 점유 확률 갱신(Occupancy Update): 역센서 모델을 이용하여 센서 측정값에 따라 각 셀의 Occupancy Probability를 갱신한다. 일반적으로 센서 광선이 장애물에 도달하기 전까지 통과한 셀은 Free Space일 가능성을 높이고, 장애물이 검출된 셀은 Occupied Space일 가능성을 높인다.
5. 반복적인 지도 갱신(Map Update): 로봇이 이동하면서 새로운 센서 측정값을 획득할 때마다 Occupancy Probability를 반복적으로 갱신하여 주변 환경에 대한 지도를 구축한다.

점유 확률은 베이즈 정리를 기반으로 갱신할 수 있으며, Log-Odds 표현을 사용하기도 한다.

Occupancy Grid Map은 센서 측정의 불확실성을 확률적으로 표현할 수 있다는 장점이 있고, 이동 로봇의 장애물 회피, 경로 계획 및 지도 작성 등에 활용된다.

따라서 Occupancy Grid Map은 로봇이 주변 환경의 장애물과 Free Space을 구분하고, 안전한 자율주행을 수행하기 위한 중요한 환경 표현 방법이다.